Построение словаря сокращений

Амосов Федор

HP Labs, СПбГУ

29 мая 2013 г.

Постановка задачи

- ... чем их ранние и средние вещи. Уже первые научно-фантастич. рассказы и повести С. отмечены вниманием к внутр. миру героев, «реалистичностью» деталей, юмором. Разрабатывая преим. жанр социально-филос. фантастики, к-рый в творчестве С. нередко приобретает черты сатирич. гротеска, авторы отстаивают гуманистич. идеал прогресса во имя человека, предостерегают против бездуховного «благоденствия», выступают против любых форм порабощения, размышляют о роли личности в обществе, об ответственности перед будущим. За последние ...
- ... что тормозить тут нельзя. Никакие "анализы через пару дней"и т.п... Праздник грядёт... В этом году день варенья приходится на понедельник. Что вызывает вопрос ...
- Ну чо, Show must go on, ёпт.

Подходы

- Отсечения
  - по частоте
  - по длине
- Случайно ли появление слова w и точки в виде $w.$?
  - Стандартные алгоритмы проверки гипотез
    - t–test
    - Pirson test χ^2
  - Алгоритмы, учитывающие специфику сокращений
    - scaled likelihood ratios (LR)
    - scaled mutual information (MI)

Результаты

Тестирование на данных проекта «Открытый корпус»
($\sim$ 73000 предложений)

%	точность	полнота	F1–мера
по частоте	34	8	13
по длине	55	38	45
t–test	28	21	24
test χ^2	47	31	37
MI	70	42	52
LR	**71**	**46**	**56**

Токенизация английских текстов (1)

- Брауновский корпус ($\sim$ 60000 предложений)
- Сокращения, извлеченные методом LR (282 кандидата)

Mr.	314
Mrs.	232
Dr.	84
St.	72
U.S.	70
Jr.	34
etc.	26
Fig.	25
p.m.	24
...	...

- На сколько улучшится работа токенайзера FreeLing с различными наборами наилучших сокращений из этого списка?

Токенизация английских текстов (2)

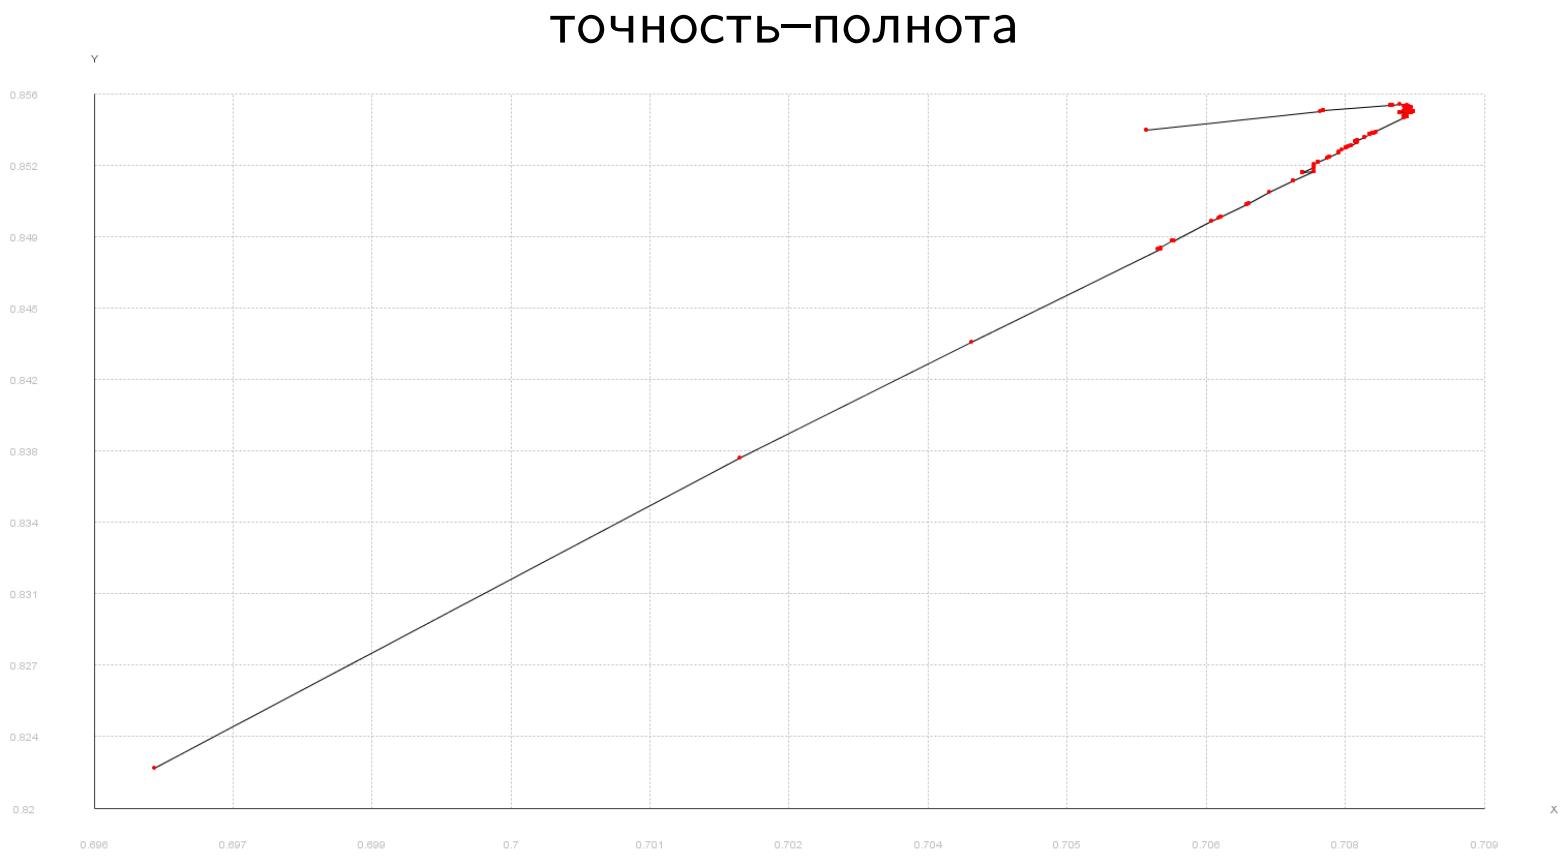

%	точность	полнота	F1–мера
без сокращений	79.9	68.8	73.9
по умолчанию	85.1	70.5	77.1
LR	**85.5**	**70.8**	**77.5**

Токенизация биомедицинских текстов (1)

- Корпус MedTag ($\sim$ 6300 предложений)
- Сокращения, извлеченные методом LR (111 кандидатов)

al.	8
e.g.	7
i.e.	6
J.	5
S.E.	5
r.h.	3
Sph.	3
Chem.	2
Ass.	2
i.v.	2
Fig.	2
...	...

- FreeLing?

Токенизация биомедицинских текстов (2)

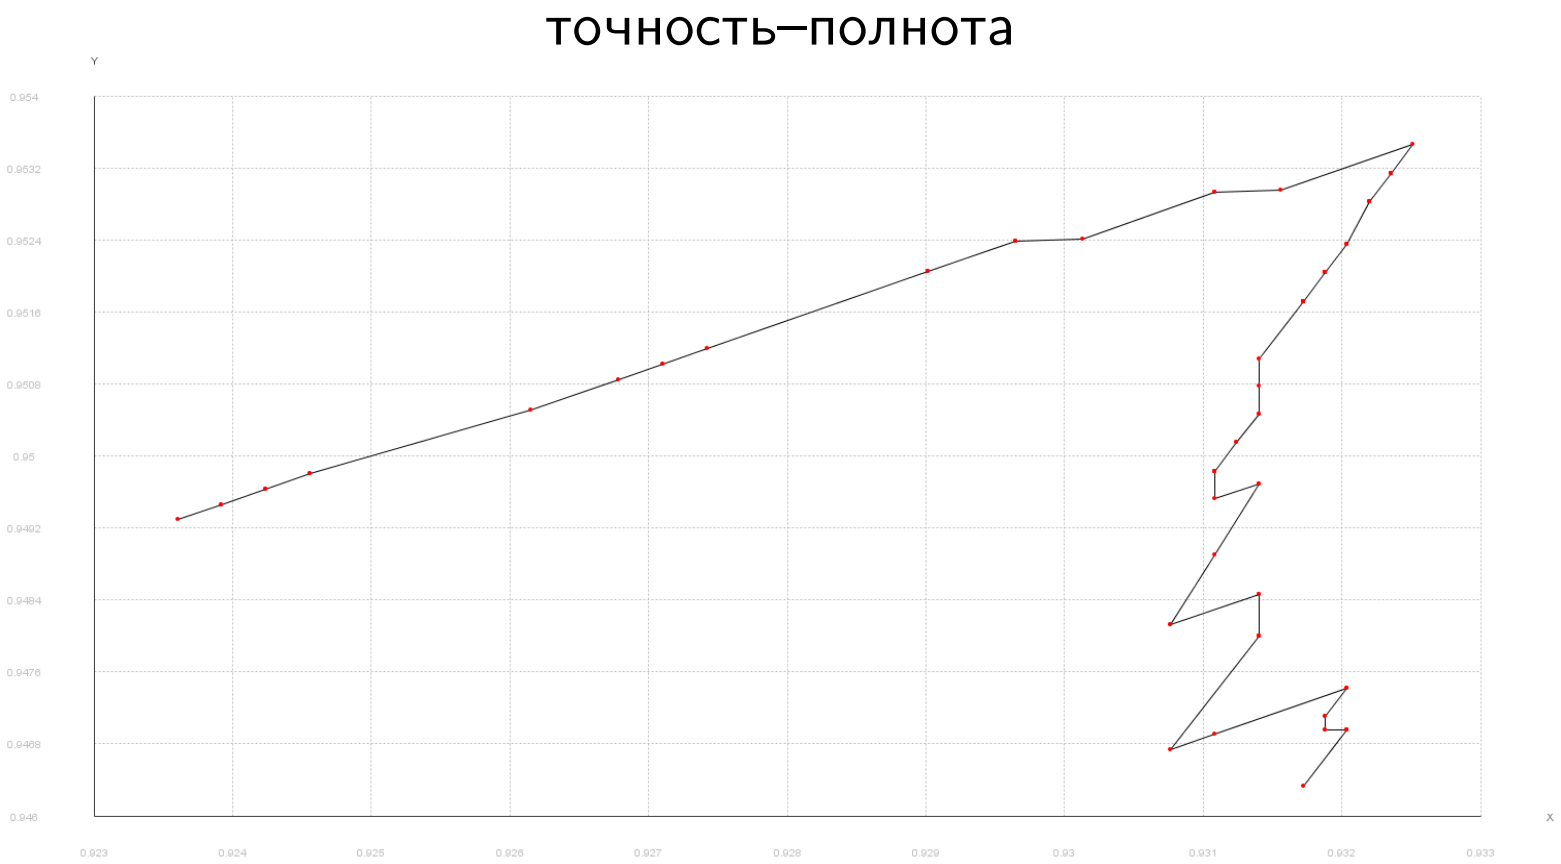

%	точность	полнота	F1–мера
без сокращений	94.6	93.2	93.9
по умолчанию	94.0	91.7	92.9
LR	**95.3**	**93.3**	**94.3**

Q&A

Спасибо за внимание!